



Instituto Politécnico Nacional
"La Técnica al Servicio de la Patria"



ESCUELA SUPERIOR DE CÓMPUTO

REPORTE DE PRÁCTICA 1

Limpieza y transformación de datos en un dataset de retail

Online Retail: validación, normalización y auditoría de transformaciones

UNIDAD DE APRENDIZAJE
C703 - Big Data / Big Data

GRUPO
7CV4

DOCENTE
Tania Rodríguez Sarabia

PERIODO
20271

INTEGRANTES

Eduardo Alonso Sánchez

2023630155

Índice

1. Introducción	1
2. Desarrollo	1
2.1. Configuración, carga y exploración	1
2.2. Nulos y duplicados	2
2.3. Tipos, reglas de negocio y cancelaciones	2
2.4. Outliers y capping	2
2.5. Normalización de productos y países	3
2.6. Segmentación y exportación	3
3. Conclusiones	4
A. Archivos de evidencia y reejecución	5

Resumen

Se limpió el conjunto Online Retail de 541,909 registros con la estrategia personalizada para la terminación de boleto 0155. Se imputaron 135,080 valores de CustomerID, se completaron 1,454 descripciones y se eliminaron 10,684 registros redundantes según la clave InvoiceNo, StockCode y CustomerID. El resultado contiene 531,225 filas, sin nulos ni duplicados en esa clave.

La cantidad se limitó a los percentiles 5 y 95, equivalentes a 1 y 30. Esta operación modificó 36,222 registros y convirtió en positivas las 10,475 cantidades negativas. Para evitar una lectura incorrecta, el archivo conserva la cantidad y el total originales, además de la bandera de cancelación. El total positivo ajustado es 8,446,757.503 libras, pero se reporta como una medida transformada y no como ingreso real.

Palabras clave: limpieza de datos, valores nulos, duplicados, outliers, retail, pandas.

1 Introducción

Los datos transaccionales suelen mezclar ventas, devoluciones, cancelaciones, identificadores faltantes y valores extremos. Online Retail reúne operaciones de un comercio británico sin tienda física entre diciembre de 2010 y diciembre de 2011. UCI registra 541,909 instancias y define los folios que comienzan con la letra C como cancelaciones [1]. La copia CSV utilizada es la distribuida por el repositorio de Databricks señalado en la consigna [2].

El objetivo de la práctica es construir un proceso reproducible de carga, validación, limpieza, transformación y exportación. El procedimiento se personaliza con los últimos cuatro caracteres de la boleto. Usé el entero 155 para aritmética y paridad, mientras que conservé la cadena 0155 en nombres, etiquetas y búsquedas. Esta distinción mantiene el cero inicial sin alterar las operaciones numéricas.

El análisis se ejecutó sobre el dataframe completo. El subconjunto de 155 filas se creó únicamente para cumplir la visualización solicitada. El notebook adjunto contiene los resultados y exporta tanto las columnas transformadas como las columnas originales necesarias para auditar cada cambio.

2 Desarrollo

2.1 Configuración, carga y exploración

El identificador numérico es 155 y el tamaño de visualización fue $N = 155 \bmod 100 + 100 = 155$. Cargué el CSV en UTF-8 y conservé InvoiceNo y StockCode como texto. El archivo original tiene ocho columnas y 541,909 filas. Su huella SHA-256 es

```
a2f79bbdd4463df6db8a3f5a50b9c980ae8f645a370bf5e2c0d6097f9e817b05
```

Esto permite comprobar que una reejecución parte del mismo insumo.

La exploración mostró 135,080 valores nulos en CustomerID, equivalentes al 24.926694 %, y 1,454 descripciones nulas, equivalentes al 0.268311 %. No se encontraron folios de factura nulos. UCI describe CustomerID como un identificador categórico, aunque el CSV lo representa inicialmente como número con nulos [1].

2.2 Nulos y duplicados

Como 155 es impar, imputé CustomerID con $10000 + 155 = 10155$. Las descripciones faltantes recibieron la etiqueta NO_DESCRIPCION_0155. El valor 10155 es un centinela analítico; no se interpreta como un cliente observado. Por ello, el resultado contiene 4,373 identificadores, de los cuales 4,372 provienen del archivo original.

Detecté 5,268 duplicados exactos. La estrategia asignada para un identificador impar eliminó repeticiones según InvoiceNo, StockCode y CustomerID, conservando la primera aparición. Pandas permite definir estas columnas mediante el parámetro subset de drop_duplicates [4]. Se retiraron 10,684 filas, el 1.971549 % del dataframe previo, y quedaron 531,225 registros.

2.3 Tipos, reglas de negocio y cancelaciones

Convertí InvoiceDate con el formato mes/día/año y hora. Las 531,225 fechas se transformaron sin valores no reconocidos. También forcé Quantity y UnitPrice a tipos numéricos. La función to_datetime documenta este tipo de conversión y el control de errores [5].

La columna Transaccion_Valida se calculó antes del tratamiento de outliers: exige cantidad y precio mayores que cero. Se obtuvieron 519,582 filas válidas y 9,139 filas cuyo folio comienza con C. La bandera Es_Cancelacion se conserva después de las transformaciones para no perder esta regla de negocio.

2.4 Outliers y capping

Para detectar outliers calculé $Q_1 = 1$, $Q_3 = 10$ e $IQR = 9$. Los límites $Q_1 - 1.5IQR = -12.5$ y $Q_3 + 1.5IQR = 23.5$ marcaron 58,337 registros. Debido a que el último dígito de la boleta es 5, apliqué capping en los percentiles 5 y 95. Los límites fueron 1 y 30, y 36,222 cantidades cambiaron. El método clip sustituye los valores fuera de los límites por el límite más cercano [3].




Figura 1. Cantidad antes y después del capping en los percentiles 5 y 95

Efecto sobre devoluciones y cancelaciones

El percentil 5 fue 1. En consecuencia, las 10,475 cantidades negativas pasaron a 1, incluidas las 9,139 cancelaciones. La columna transformada produce 528,721 filas con cantidad y precio positivos, pero esa cifra no reemplaza las 519,582 transacciones válidas según los datos originales. El CSV conserva Quantity_Original, Total_Transaccion_Original, Transaccion_Valida y Es_Cancelacion para auditar el sesgo.

Los cinco registros de mayor valor original incluyen los folios 581483 y 541431, con 168,469.60 y 77,183.60 libras. Después del capping, el mayor total ajustado es 38,970.00 libras y pertenece al folio C556445, una cancelación. Esta inversión del resultado muestra por qué el total ajustado no debe presentarse como venta real. Los dos listados completos se exportaron como CSV.

2.5 Normalización de productos y países

Normalicé los países a mayúsculas, retiré espacios en los extremos y colapsé espacios repetidos. Antes de la unificación había 1,324 productos con más de una descripción. El código 90155 contiene la cadena 0155 en siete filas; se tomó su descripción modal y se agregó el sufijo [UNIFICADO_0155].

La categoría se obtuvo de StockCode. Se clasificaron 34 filas como REGALO_0155, 53,925 como PRODUCTO_ESPECIAL y 477,266 como PRODUCTO_NORMAL. El orden de las reglas da prioridad a la presencia de gift; después se revisa si existe cualquier letra.

2.6 Segmentación y exportación

El umbral dinámico fue $2023630155 \bmod 50 + 10 = 15$. Con el total ajustado, 341,842 registros quedaron en BAJO_VALOR y 189,383 en ALTO_VALOR. La figura 2 presenta esta comparación.




Figura 2. Registros por categoría de cliente con umbral ajustado de 15 libras

El conteo de filas que contienen la cadena 0155 es 134,566. La búsqueda se hizo en InvoiceNo, StockCode, Description, CustomerID y Country. La mayoría procede del identificador imputado 10155; el conteo no equivale a clientes reales ni a productos distintos.

Cuadro 1. Métricas principales de la práctica

Métrica	Resultado
Filas originales	541,909
Filas finales	531,225
Transacciones válidas con datos originales	519,582
Cancelaciones	9,139
Cientes únicos, incluido el centinela	4,373
Cientes reales distintos	4,372
Productos únicos	4,070
Total positivo original	10,587,015.733 GBP
Total positivo ajustado	8,446,757.503 GBP
Total neto original	9,683,331.923 GBP
Total neto ajustado	8,424,633.383 GBP
Filas que contienen 0155	134,566

Calidad final

La completitud es 100 %. La unicidad de la clave de negocio, la coherencia de la bandera de cancelación, la normalización de países y el cumplimiento del rango capeado también son 100 % según las validaciones programadas. Estas métricas verifican reglas concretas del proceso; no garantizan que cada importe represente una venta económicamente válida.

3 Conclusiones

Completé los nueve puntos de limpieza sobre el dataframe completo y dejé un notebook ejecutado que reproduce la descarga, las decisiones personalizadas, las visualizaciones y las exportaciones. La clave de negocio quedó sin repeticiones, se resolvieron los valores nulos y todas las fechas se convirtieron al tipo esperado. Los archivos de salida permiten rastrear cada fila hasta su posición ordinal en el CSV original.

La decisión con mayor impacto fue el capping. Al fijar el límite inferior en 1, el procedimiento cambió devoluciones y cancelaciones en cantidades ajustadas positivas. Por esta razón distinguí el total positivo original de 10,587,015.733 libras, el total positivo ajustado de 8,446,757.503 libras y los totales netos correspondientes. Ninguna de estas sumas debe llamarse ingreso confirmado sin excluir cancelaciones y validar el significado contable de los registros.

La limitación principal es la imputación de 135,080 identificadores con un único centinela. La operación resuelve completitud, pero agrupa transacciones sin cliente conocido como si pertenecieran a una misma entidad. Para un análisis de clientes posterior se debe excluir el valor 10155 o tratarlo como categoría desconocida. Con estas precauciones, el producto es reproducible y defendible durante la revisión de la práctica.

Referencias

- [1] Daqing Chen. Online retail, 2015. URL <https://archive.ics.uci.edu/dataset/352/online+retail>.
- [2] Databricks. Spark: The definitive guide - online retail dataset, s. f. URL <https://github.com/databricks/Spark-The-Definitive-Guide/tree/master/data/retail-data/all>. Consulta: 6 de septiembre de 2026.
- [3] pandas development team. pandas.series.clip, s. f.. URL <https://pandas.pydata.org/docs/reference/api/pandas.Series.clip.html>. Consulta: 6 de septiembre de 2026.
- [4] pandas development team. pandas.dataframe.drop_duplicates, s. f.. URL https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.drop_duplicates.html. Consulta: 6 de septiembre de 2026.
- [5] pandas development team. pandas.to_datetime, s. f.. URL https://pandas.pydata.org/docs/reference/api/pandas.to_datetime.html. Consulta: 6 de septiembre de 2026.

A Archivos de evidencia y reejecución

El notebook ejecutado se encuentra en notebooks/practica_01_limpieza_datos_0155.ipynb. El archivo INSTRUCCIONES.md explica cómo abrirlo en Google Colab y cómo reconstruirlo de forma local. Los scripts de scripts/ generan una copia limpia del notebook y la ejecutan con errores detenidos.

Las exportaciones principales son:

- datos/processed/online_retail_limpio_Eduardo_Alonso_Sanchez_0155.csv;
- datos/processed/reporte_estadistico_0155.json y su versión CSV;
- los listados de las cinco transacciones mayores, original y ajustado;
- las dos gráficas PNG usadas en este reporte.

El archivo original se conserva en datos/raw/ y su huella se registra en el notebook y el reporte estadístico. De esta forma, una exposición puede partir del notebook ya ejecutado o demostrar la corrida completa sin depender del PDF.