



Instituto Politécnico Nacional  
"La Técnica al Servicio de la Patria"



ESCUELA SUPERIOR DE CÓMPUTO

---

REPORTE DE PRÁCTICA 2

# Introducción a Apache Spark

Análisis exploratorio del conjunto de datos Adult Income

UNIDAD DE APRENDIZAJE  
C703 – Big Data / Big Data

GRUPO  
7CV4

DOCENTE  
Tania Rodríguez Sarabia

PERIODO  
20271

ESTUDIANTE

Eduardo Alonso Sánchez

2023630155

Índice

|                                                    |   |
|----------------------------------------------------|---|
| 1. Introducción                                    | 1 |
| 2. Datos y procedimiento                           | 1 |
| 3. Resultados                                      | 1 |
| 3.1. Carga y esquema . . . . .                     | 1 |
| 3.2. Ocupaciones más frecuentes . . . . .          | 2 |
| 3.3. Horas semanales por género . . . . .          | 2 |
| 3.4. Registros con país de origen México . . . . . | 2 |
| 4. Conclusiones                                    | 3 |
| A. Reproducción y archivos de salida               | 4 |

## Resumen

Analicé el archivo `adult.csv` con Apache Spark. La lectura con encabezados e inferencia de tipos produjo 48 842 registros y 15 columnas. Agrupé las ocupaciones, calculé el promedio de horas semanales por género y filtré los registros cuyo país de origen está codificado como `Mexico`. La ocupación más frecuente fue `Prof-specialty` (6 172 registros). El filtro de México devolvió 951 registros. El resultado de ocupaciones se conservó como CSV generado por Spark.

**Palabras clave:** PySpark, DataFrame, análisis exploratorio, Adult Income.

## 1 Introducción

El conjunto Adult Income reúne registros demográficos usados originalmente para estudiar la categoría de ingresos mayores o menores de 50 000 dólares anuales [3]. Para esta práctica utilicé la copia `adult.csv` del repositorio señalado en el enunciado [2]. El archivo contiene variables como ocupación, género, horas trabajadas por semana y país de origen.

Mi objetivo fue ejecutar un flujo básico de Spark sobre datos reales: cargar el CSV con tipos inferidos, explorar su esquema y cantidad de filas, aplicar filtros y agrupaciones, y guardar una tabla de resultados. El análisis es descriptivo; las comparaciones que siguen corresponden a los registros del archivo y no se extrapolan a una población.

## 2 Datos y procedimiento

Descargué `adult.csv` del repositorio indicado. El archivo tiene 5 326 368 bytes y su huella SHA-256 es `1f13ee2bf9d7c66098429281ab91fa1b51cbabd3b805cc365b3c6b44491ea2c0`. Ejecuté el script `scripts/analisis_censo.py` con PySpark 4.2.0 en modo local de dos núcleos. La sesión se llamó `Análisis Censo`.

La lectura usó `header=True` e `inferSchema=True`, como permite la API de Spark [1]. Después, `count()` obtuvo el total. Para las ocupaciones agrupé por `occupation`, conté las filas y ordené de mayor a menor frecuencia; ante un empate, ordené alfabéticamente. Para el promedio agrupé por `gender` y apliqué `avg` sobre `hours-per-week`. El filtro de México comparó de forma exacta `native-country` con `Mexico`.

Conservé los valores tal como aparecen en el CSV. En particular, `?` se mantiene como una categoría de ocupación: figura en 2 809 filas y entra en el grupo de las diez más frecuentes. No traté ese símbolo como dato faltante porque la consigna pide explorar el archivo cargado, sin una etapa de limpieza. Para guardar la tabla, usé el escritor CSV de Spark con encabezados y una sola partición de salida.

## 3 Resultados

### 3.1 Carga y esquema

Spark leyó 48 842 registros distribuidos en 15 columnas. Inferió tipos enteros para `age`, `fnlwgt`, `educational-num`, `capital-gain`, `capital-loss` y `hours-per-week`; las nueve columnas restantes quedaron como texto. Esta comprobación importa porque el promedio semanal se calculó sobre un campo numérico, sin conversión manual.

### 3.2 Ocupaciones más frecuentes

La tabla 1 contiene el resultado de agrupar y contar la columna `occupation`. `Prof-specialty` encabeza la lista, con 6 172 registros. Las tres primeras categorías tienen frecuencias cercanas; la diferencia entre la primera y la tercera es de 86 registros.

Cuadro 1. Diez valores más frecuentes de `occupation`.

| Ocupación         | Registros |
|-------------------|-----------|
| Prof-specialty    | 6 172     |
| Craft-repair      | 6 112     |
| Exec-managerial   | 6 086     |
| Adm-clerical      | 5 611     |
| Sales             | 5 504     |
| Other-service     | 4 923     |
| Machine-op-inspct | 3 022     |
| ?                 | 2 809     |
| Transport-moving  | 2 355     |
| Handlers-cleaners | 2 072     |

El signo ? representa una etiqueta no especificada dentro del archivo, no una profesión. Lo dejé visible para que el conteo del CSV exportado coincida con el dato original.

### 3.3 Horas semanales por género

La tabla 2 presenta la media de `hours-per-week` para cada valor de `gender`. En este archivo, el promedio del grupo Male supera al del grupo Female por alrededor de 6,02 horas semanales. La tabla también muestra la cantidad de registros que intervienen en cada media.

Cuadro 2. Horas trabajadas por semana agrupadas por `gender`.

| Valor de <code>gender</code> | Registros | Promedio de horas |
|------------------------------|-----------|-------------------|
| Female                       | 16 192    | 36,40             |
| Male                         | 32 650    | 42,42             |

### 3.4 Registros con país de origen México

El filtro exacto `native-country = Mexico` devolvió 951 filas. El script muestra en consola las primeras veinte, con edad, tipo de empleo, estudios, ocupación, género, horas semanales, país de origen y categoría de ingresos. La tabla 3 reproduce cinco registros iniciales para dejar constancia del filtro aplicado.

Cuadro 3. Cinco registros iniciales con `native-country = Mexico`.

| Edad | Estudios | Ocupación         | Género | Horas |
|------|----------|-------------------|--------|-------|
| 39   | 7th-8th  | Craft-repair      | Male   | 40    |
| 38   | 9th      | Exec-managerial   | Male   | 54    |
| 30   | HS-grad  | Machine-op-inspct | Male   | 40    |
| 21   | 5th-6th  | Machine-op-inspct | Male   | 38    |
| 52   | 1st-4th  | Machine-op-inspct | Male   | 40    |

La columna nombra el país de origen registrado en el dataset. Por sí sola, no permite inferir residencia actual, nacionalidad legal ni historia migratoria.

## 4

**Conclusiones**

El flujo de PySpark cubrió la carga, la exploración inicial, tres consultas demográficas y la exportación solicitada. Las acciones `count()`, `show()` y `write.csv()` materializaron resultados a partir de las transformaciones. El CSV de las diez ocupaciones quedó dentro de `resultados/`, en la carpeta identificada con mi nombre completo.

El dato ? en ocupación muestra una limitación concreta: una categoría entre las diez más frecuentes no identifica un oficio. Si se necesitara comparar profesiones conocidas, el siguiente paso sería definir y documentar un tratamiento para esos 2 809 registros antes de repetir el conteo. En esta entrega los conservé para respetar el archivo original y hacer verificables los resultados.

## Referencias

- [1] Apache Software Foundation. Pyspark dataframe reader.csv, s. f. URL <https://spark.apache.org/docs/4.2.0/api/python/reference/pyspark.sql/api/pyspark.sql.DataFrameReader.csv.html>. Documentación de Apache Spark 4.2.0.
- [2] saravrajavelu. Adult income analysis: adult.csv. Repositorio de GitHub, s. f. URL <https://github.com/saravrajavelu/Adult-Income-Analysis/blob/master/adult.csv>. Archivo de datos usado en esta práctica.
- [3] UCI Machine Learning Repository. Adult, s. f. URL <https://archive.ics.uci.edu/dataset/2/adult>. Descripción y procedencia del conjunto de datos.

## A Reproducción y archivos de salida

El proyecto incluye el CSV original en `datos/raw/adult.csv`, el script de análisis en `scripts/`, un resumen estructurado en `resultados/resumen.json` y la carpeta CSV que genera Spark para las diez ocupaciones.

```
1 uv venv .venv
2 uv pip install --python .venv/bin/python -r requirements.txt
3 make analisis
4 make
```

**Código 1.** Ejecución local del análisis y compilación del reporte.

Spark guarda un CSV como directorio con un archivo `part-*.csv`, además de archivos de control. La carpeta de salida lleva mi nombre completo, según la consigna. El resumen JSON registra la versión de Spark, el esquema, los totales y la huella del archivo de entrada para repetir la comprobación.